

Априорное ранжирование топологий в многоагентных LLM-системах

24 мая 2026 г.

1 Введение

В многоагентных системах на базе LLM качество решения сложных задач зависит от топологии коммуникации между агентами и выбора подходящего промпта для каждого из агентов [1]. Так G-Designer [2], показывают, что правильно выбранная топология может значительно повысить производительность при одновременном снижении расхода токенов.

Существующие подходы требуют либо ручной настройки, либо многократной оптимизации промптов и дорогостоящих запусков полной MAS для каждой новой задачи. Мы формулируем задачу *суррогатного предсказания* максимальной производительности топологии для ранжирования топологий-кандидатов. В качестве решения предлагаются гибридные few/zero-shot решения, опирающиеся на структурные характеристики и генерализацию с помощью RNI [3].

2 Формальная постановка задачи

Дано:

- Множество агентов $\mathcal{A} = \{a_1, \dots, a_m\}$, каждый агент a_i характеризуется ролью, типом LLM и другими атрибутами.
- Базовый запрос $q \in \mathcal{Q}$.
- Пространство возможных топологий коммуникации $\mathcal{T}$, где каждая топология $T \in \mathcal{T}$ представляется ориентированным графом $G_T = (V, E)$, где $V = \mathcal{A} \cup \{v_{\text{task}}\}$ (вершины — агенты плюс виртуальный узел задачи), а рёбра E определяют направления передачи сообщений.

Вход: набор агентов $\mathcal{A}$, базовый запрос q и кандидатная топология T .

Выход: оценка $\hat{p}(T \mid \mathcal{A}, q) \in \mathbb{R}$, представляющая *максимальную достижимую производительность* системы при использовании топологии T (например, accuracy, pass@1 или комбинированная метрика эффективность/качество).

Целевая функция:

$$T^* = \arg \max_{T \in \mathcal{T}} \hat{p}(T \mid \mathcal{A}, q)$$

при этом минимизируя необходимость в оптимизации промптов и многократных оценках полной MAS.

Ограничения:

- Минимизация шагов оптимизации промптов при обучении.
- Инференс суррогата не требует запуска MAS на топологии.
- Перенос знаний между разными задачами (task-adaptive).

3 Предлагаемые методы

3.1 Прокси на синтетических топологиях: структурные метрики и эмбединги агентов

В качестве бейзлайна предлагается **гибридный прокси-метод** для быстрой априорной оценки и выбора топологий коммуникации $T \in \mathcal{T}$. Подход объединяет семантические эмбединги ролей агентов и запроса с частичной случайной инициализацией вершин, за которой следует вычисление энтропийно-структурных метрик графа. Это позволяет выполнять zero/few-shot ранжирование кандидатных топологий без полных запусков MAS и оптимизации промптов под конкретную задачу.

3.1.1 Формальная постановка прокси-подхода

При наличии множества агентов $\mathcal{A} = \{a_1, \dots, a_m\}$ с их ролями и базового запроса $q \in \mathcal{Q}$, мы генерируем пул кандидатных ориентированных ациклических графов $G_T = (V, E)$, где $V = \mathcal{A} \cup \{v_{\text{task}}\}$, а v_{task} — виртуальный узел задачи (как определено в формальной постановке задачи). Методология генерации предложена в разделе 3.1.2.

Признаки вершин формируются гибридным образом:

$$\mathbf{x}_i = \text{embedding}(a_i) + \varepsilon \cdot \mathcal{N}(0, \mathbf{I}), \quad i \in A,$$

$$\mathbf{x}_{\text{task}} = \text{embedding}(q) + \varepsilon \cdot \mathcal{N}(0, \mathbf{I}),$$

где ε контролирует силу компоненты RNI. Такая частичная рандомизация наследует свойства универсальности MPNN с RNI [3], позволяя прокси различать топологии за пределами ограничений 1-WL и обобщать результаты избегая переобучения.

На каждом кандидатном графе G_T с гибридной матрицей признаков $\mathbf{X}$ вычисляется композитный прокси-score $\hat{p}(T \mid A, q)$ в виде взвешенной суммы следующих компонент:

- **Структурная энтропия (SE)** [4]: одномерная и path-wise энтропия, вычисляемая вдоль ориентированных путей, исходящих из v_{task} , что позволяет количественно оценить неопределённость и разнообразие информации в структуре коммуникации.

$$d_u = \sum_{v \in \mathcal{N}(u)} I(u, \rho, v), \quad \mathcal{H}_1(G_T) = - \sum_{u \in V} \frac{d_u}{\text{vol}(G_T)} \log_2 \left(\frac{d_u}{\text{vol}(G_T)} \right),$$

где $I(u, \rho, v)$ — вес ребра (self-information или $1 - \cos(\mathbf{x}_u, \mathbf{x}_v)$), $\text{vol}(G_T) = \sum_u d_u$. Для path-wise SE суммирование ведётся только по путям от v_{task} .

- **Энтропия фон Неймана графа $H_{VN}(G_T)$** : спектральная энтропия на основе собственных значений нормализованной матрицы Лапласа, измеряющая общую сложность графа и свойства смешивания информации.

$$H_{VN}(G_T) = - \sum_{i=2}^{|V|} \frac{\lambda_i}{\text{tr}(L)} \log_2 \left(\frac{\lambda_i}{\text{tr}(L)} \right),$$

где L — нормализованная матрица Лапласа графа G_T , а λ_i — её собственные значения ($\lambda_1 = 0$).

- **Энтропия скорости случайных блужданий H_{flow}** : условная энтропия потока информации, начинающегося из v_{task} , отражающая предсказуемость и отсутствие узких мест.

$$H_{\text{flow}} = - \sum_i \pi_i \sum_j P_{ij} \log_2 P_{ij},$$

где $P = D^{-1}A$ — матрица переходных вероятностей случайного блуждания, π — стационарное распределение (часто вычисляется только для путей, начинающихся из v_{task}).

- **Прокси-метрика разнообразия информации (проху-IDS)** из работы GEMMAS [5]: энтропия попарных косинусных сходств между эмбедингами вершин, взвешенная по наличию рёбер.

$$\text{проху-IDS} = \frac{\sum_{i,j} w_{ij}(1 - \cos(\mathbf{x}_i, \mathbf{x}_j))}{\sum_{i,j} w_{ij}}, \quad H_{\text{sem}} = - \sum p(S_{ij}) \log_2 p(S_{ij}),$$

где $w_{ij} = 1$ при наличии ребра (или взвешено по длине пути), $S_{ij} = \cos(\mathbf{x}_i, \mathbf{x}_j)$, а $p(S_{ij})$ — нормированное распределение сходств.

- **Классические структурные метрики:** обратный диаметр графа, центральность узла задачи (betweenness/closeness) и спектральный зазор.

$$\text{diam}^{-1}(G_T), \quad C_{\text{task}} = \text{betweenness}(v_{\text{task}}) \text{ или } \text{closeness}(v_{\text{task}}), \quad \Delta = \lambda_2(L) \quad (\text{спектральный зазор}).$$

Таким образом, предсказание имеет вид

$$\hat{p}(T) = \sum_k w_k \cdot f_k(G_T, \mathbf{X}),$$

где f_k — нормированные значения перечисленных метрик.

3.1.2 Методология синтетической генерации бенчмарка

Для калибровки весов w_k в композитном прокси-score $\hat{p}(T)$ и оценки качества гибридного подхода предлагается использовать контролируемый **синтетический бенчмарк**. Он позволяет проводить быструю валидацию метода без дорогостоящих запусков на реальных бенчмарках (MMLU, HumanEval, GSM8K и др.).

Методология генерации бенчмарка состоит из следующих шагов:

1. **Генерация синтетических запросов.** Создаётся набор запросов q , например, запросы из бенчмарков или сгенерированные с помощью вспомогательной модели.

2. **Формирование наборов агентов.** Генерируются наборы из агентов с разнообразными ролями. Для каждого агента вычисляется базовый эмбединг роли, к которому добавляется компонента случайной инициализации.

3. **Генерация пула кандидатных топологий.** Для каждой пары (набор агентов, запрос) создаётся большой пул из ориентированных ациклических графов $G_T = (V, E)$, где $V = A \cup \{v_{\text{task}}\}$. Графы генерируются с помощью моделей случайных графов или набора популярных топологий: CoT, ToT, GoT. Каждый граф обязательно содержит виртуальный узел задачи v_{task} .

4. **Получение ground truth.** На небольшой подвыборке графов выполняется полный запуск MAS с фиксированными базовыми промптами. В качестве целевых метрик используются accuracy, pass@1.

5. **Разделение данных и калибровка.** Полученный датасет делится на обучающую, валидационную и тестовую выборки в соотношении. Веса w_k в формуле

$$\hat{p}(T) = \sum_k w_k \cdot f_k(G_T, \mathbf{X})$$

калибруются с помощью вспомогательной модели. Качество калибровки оценивается исходя из близости между предсказанным прокси-score и реальной производительностью MAS.

Такой синтетический бенчмарк наследует идеи контролируемых датасетов из [3]. Дополнительно, он обеспечивает быструю и воспроизводимую калибровку метода, делая его применимым для zero-shot адаптации топологий под ранее не встречавшиеся задачи и домены.

3.2 GNN для предсказания качества топологии

В качестве развития идеи предлагается использовать архитектуры GNN. Такой подход делает модель универсальным аппроксиматором функций на графах фиксированного порядка, и позволит учесть более сложные особенности топологии.

3.2.1 Применение GNN с RNI в задаче zero-shot оценки топологии

Пусть $G = (V, E, \mathbf{X})$ — размеченный граф, где V — множество вершин - агентов, E — множество рёбер (топология коммуникации), а $\mathbf{X} \in \mathbb{R}^{|V| \times d_{\text{det}}}$ — матрица начальных признаков узлов, например, эмбедингов агентов из 3.1.1.

В MPNN начальные признаки узла $v \in V$ задаются как:

$$\mathbf{h}_v^{(0)} = \mathbf{x}_v \in \mathbb{R}^{d_{\text{det}}}.$$

При применении RNI начальные признаки модифицируются следующим образом:

$$\mathbf{h}_v^{(0)} = \text{concat}(\mathbf{x}_v, \mathbf{r}_v) \quad \text{или} \quad \mathbf{h}_v^{(0)} = \mathbf{r}_v,$$

где $\mathbf{r}_v$ — случайный вектор, сэмплированный независимо для каждого узла и каждого запуска модели.

3.2.2 Предполагаемая архитектура суррогатной модели

Пусть $\mathbf{x}_v$ — начальные признаки узла v (после RNI). Модель выполняет L слоёв message passing:

$$\mathbf{h}_v^{(l+1)} = \text{UPDATE}(\mathbf{h}_v^{(l)}, \text{AGGREGATE}(\{\mathbf{h}_u^{(l)} \mid u \in \mathcal{N}(v)\})),$$

где AGGREGATE — sum/mean/max, UPDATE — GCNConv или аналогичный слой с активацией ELU.

После L слоёв применяется глобальный readout (global max-pool):

$$\mathbf{g} = \text{global_max_pool}(\{\mathbf{h}_v^{(L)}\}_{v \in V}).$$

Финальный MLP-регрессор предсказывает скалярную оценку производительности:

$$\hat{p}(T \mid \mathcal{A}, q) = \text{MLP}(\mathbf{g}).$$

4 Discussion

4.1 Преимущества

- Эффективность: Один раз обученная модель позволяет выбирать топологию zero-shot без циклической оптимизации промптов.
- Интеграция с существующими работами: Может дополнять G-Designer (замена VAE-декодера на суррогат), использоваться в REINFORCE функционале GPTSwarm [1], ограничивать набор топологий для перебора для контроля стоимости оптимизации.
- Робастность: Частичный RNI обеспечивает хороший баланс между выразительностью и индуктивным смещением.
- Переносимость: Благодаря синте является универсальным аппроксиматором и способна различать топологии, неразличимые стандартными GNN.

4.2 Ограничения

- Качество эмбеддингов: Простые модели-эмбеддеры могут не различать запросы для специфических доменов, итоговый результат зависит от обучающего датасета
- Масштаб: Некоторые подходы, например, спектральная энтропия, обладает кубической сложностью по числу вершин, поэтому сложно перекладываются на большие графы агентов
- Оптимизация промпта: Для качественной разметки топологий необходима оптимизация промптов агентов под широкий набор бенчмарков. Это дорогостоящая процедура, которую можно оптимизировать с помощью готовых фреймворков для автоматизации перебора, например EvoPrompt [6] и GigaEvo [7].

4.3 Альтернативные подходы

- Индустриальные решения: Топологии вроде CoT, GoT не требуют оптимизации и демонстрируют высокое качество в мульти-агентных системах [8], и широко применяются на практике.
- Адаптивные подходы: AMAS [9] — расширение подхода GPTSwarm с помощью LoRA для выбора топологии внутри бенчмарка исходя из текста запроса q , и MetaGen [10] — эволюционного подхода, который динамически меняет промпты-роли разных агентов и обновляет топологию.

Список литературы

- [1] M. Zhuge, W. Wang, L. Kirsch, F. Faccio, D. Khizbullin, and J. Schmidhuber, “Language agents as optimizable graphs,” 2024. [Online]. Available: <https://arxiv.org/abs/2402.16823>
- [2] G. Zhang, Y. Yue, X. Sun, G. Wan, M. Yu, J. Fang, K. Wang, T. Chen, and D. Cheng, “G-designer: Architecting multi-agent communication topologies via graph neural networks,” 2025. [Online]. Available: <https://arxiv.org/abs/2410.11782>
- [3] R. Abboud, İsmail İlkan Ceylan, M. Grohe, and T. Lukasiewicz, “The surprising power of graph neural networks with random node initialization,” 2021. [Online]. Available: <https://arxiv.org/abs/2010.01179>
- [4] Y. Wei, X. Yu, T. Pan, A. Li, and L. Du, “Structural entropy guided agent for detecting and repairing knowledge deficiencies in llms,” 2025. [Online]. Available: <https://arxiv.org/abs/2505.07184>
- [5] J. Lee, R. Chang, D. Kwon, H. Singh, and N. Verma, “Gemmas: Graph-based evaluation metrics for multi agent systems,” 2025. [Online]. Available: <https://arxiv.org/abs/2507.13190>
- [6] Q. Guo, R. Wang, J. Guo, B. Li, K. Song, X. Tan, G. Liu, J. Bian, and Y. Yang, “Evoprompt: Connecting llms with evolutionary algorithms yields powerful prompt optimizers,” 2025. [Online]. Available: <https://arxiv.org/abs/2309.08532>
- [7] V. Khrulkov, A. Galichin, D. Bashkurov, D. Vinichenko, O. Travkin, R. Alferov, A. Kuznetsov, and I. Oseledets, “Gigaevo: An open source optimization framework powered by llms and evolution algorithms,” 2025. [Online]. Available: <https://arxiv.org/abs/2511.17592>
- [8] M. Besta, N. Blach, A. Kubicek, R. Gerstenberger, M. Podstawski, L. Gianinazzi, J. Gajda, T. Lehmann, H. Niewiadomski, P. Nyczyk, and T. Hoefler, “Graph of thoughts: Solving elaborate problems with large language models,” *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 38, no. 16, p. 17682–17690, Mar. 2024. [Online]. Available: <http://dx.doi.org/10.1609/aaai.v38i16.29720>
- [9] H. Y. Leong, Y. Li, Y. Wu, W. Ouyang, W. Zhu, J. Gao, and W. Han, “Amas: Adaptively determining communication topology for llm-based multi-agent system,” 2025. [Online]. Available: <https://arxiv.org/abs/2510.01617>
- [10] Y. Wang, J. Zhao, H. Xie, H. Ma, Y. Lei, S. Liu, X. Song, Z. Zhang, and H. Zhang, “Metagen: Self-evolving roles and topologies for multi-agent llm reasoning,” 2026. [Online]. Available: <https://arxiv.org/abs/2601.19290>